

Rapport de Projet de fin d'année

Parkinson's Disease Prediction Using Machine Learning and
Feature Selection Methods



Réalisées par : **KHAIDER Mohamed**

Filière : **Master AIDC**

Établissement : **FST Beni mellal**

Encadrant : **Pr. Mourad NACHAOUI**

Soumis dans le cadre du module : **Projet d'AI**

Table des matières

Liste des tableaux	3
1 Contexte général du projet	5
1.1 La maladie de Parkinson	5
1.2 Les défis du diagnostic précoce	6
Les défis du diagnostic précoce	6
1.3 Apport de l'intelligence artificielle	7
2 État de l'art	8
2.1 Méthodes de diagnostic assisté par apprentissage automatique	8
Méthodes de diagnostic assisté par apprentissage automatique	8
2.2 Études récentes sur la prédiction de la maladie de Parkinson	8
Études récentes sur la prédiction de la maladie de Parkinson	8
2.3 Synthèse	9
Synthèse	9
3 Position du problème	10
3.1 Problématique générale	10
3.2 Objectif du travail	10
3.3 Formulation du problème	11
3.4 Méthodologie adoptée	11
3.5 Mesures de performance	12
3.6 Résumé de la démarche	13
4 Méthodologie de résolution	14
4.1 Jeu de données	14
4.2 Prétraitement	14
4.3 Modélisation : algorithmes de classification	16
4.3.1 Environnement d'implémentation	19
4.4 Choix des hyperparamètres	20
4.5 Pipeline de traitement	21
4.6 Espaces de résultats et visualisations	22

5	Méthodologie de validation des résultats numériques	23
5.1	Jeu de données utilisé	23
5.2	Protocole expérimental	23
5.3	Analyse de la matrice de corrélation	23
5.4	Types de simulations réalisées	25
5.4.1	Sans sélection de caractéristiques	25
5.4.2	Avec sélection de caractéristiques basée sur des méthodes <i>filter-based</i>	26
5.4.3	Avec sélection de caractéristiques basée sur des méthodes <i>wrapper-based</i>	29
5.5	Comparaison et évaluation des performances	36
5.5.1	Tableaux comparatifs	36
5.6	Analyse des résultats	37
5.6.1	Interprétation	37
5.6.2	Discussion sur les performances	38
	Conclusion Générale	40
	Annexe : Code source	42

Liste des tableaux

5.1	Performances des classifieurs sans sélection de caractéristiques	26
5.2	Résultats avec Information Gain + Validation croisée (10 folds)	27
5.3	Résultats avec PCA + Validation croisée (10 folds)	27
5.4	Résultats avec CfsSubsetEval + Best First	27
5.5	Résultats avec CfsSubsetEval + Greedy Stepwise	28
5.6	Résultats avec CfsSubsetEval + PSO	29
5.7	Performance des Classifieurs avec Wrapper-based (First Best, base=Naïve Bayes)	30
5.8	Résultats avec Wrapper-based (Greedy Stepwise, base = Naïve Bayes) . .	30
5.9	Résultats avec Wrapper PSO (base = Naïve Bayes pour sélection des features)	30
5.10	Résumé des performances FIRST BEST WRAPPED (BASE = CSVM, Validation croisée 10-fold)	31
5.11	Résumé des performances wrapped greedy stepwise (base = SVM, Validation croisée 10-fold)	31
5.12	Résumé des performances (PSO avec c-SVM pour sélection des features)	31
5.13	Performance des Classifieurs - Wrapper First Best (NuSVM indirect) . .	32
5.14	Performance des Classifieurs - Wrapper Greedy StepWise (NuSVM indirect)	32
5.15	Performance des Classifieurs - Wrapper PSO (NuSVM)	32
5.16	Résultats avec Wrapper-Based (MLP base) + First Best	33
5.17	Résultats avec Wrapper-Based (MLP base) + Greedy StepWise	33
5.18	Performance des classifieurs avec PSO + MLP	33
5.19	Résultats moyens (10-fold CV) avec Wrapper-based (KNN, First Best) .	34
5.20	Résultats moyens (10-fold CV) avec Wrapper-based (KNN, Greed StepWise)	34
5.21	Résultats avec Wrapper-based PSO (base KNN)	35
5.22	Résultats sans sélection de caractéristiques	35
5.23	Récapitulatif de la précision des classifieurs avec des méthodes de sélection de caractéristiques basées sur des filtres	36
5.24	Meilleurs résultats pour les techniques basées sur les wrappers	36
5.25	Comparaison entre les techniques basées sur les filtres et les wrappers . .	37

Introduction Générale

Cette étude se concentre sur le potentiel des signaux vocaux comme biomarqueurs de la pathologie. En utilisant des algorithmes d'apprentissage supervisé, nous cherchons à améliorer la précision du dépistage automatique. L'enjeu central réside dans la sélection pertinente des caractéristiques acoustiques pour éviter le surapprentissage et optimiser les performances des classifieurs. Nous avons ainsi testé et comparé diverses stratégies de sélection de variables (notamment PCA, Information Gain et PSO) sur un corpus de 240 enregistrements vocaux. Cette démarche comparative permet de confronter nos résultats à l'état de l'art et d'identifier les configurations algorithmiques les plus robustes pour la détection précoce de la MP.

Chapitre 1

Contexte général du projet

1.1 La maladie de Parkinson

La maladie de Parkinson (MP), décrite pour la première fois en 1817 par James Parkinson dans son ouvrage *An Essay on the Shaking Palsy*, est une pathologie neurodégénérative progressive affectant le système nerveux central. Deuxième maladie neurodégénérative la plus fréquente après Alzheimer, elle touche environ 1 % de la population mondiale de plus de 65 ans, avec une incidence variant entre 11 et 19 nouveaux cas par an pour 100 000 habitants en Europe, et une prévalence pouvant atteindre 257 cas pour 100 000.

La MP se manifeste principalement entre 60 et 65 ans, période considérée comme critique pour son apparition. Elle est légèrement plus fréquente chez les hommes, avec un ratio d'incidence homme/femme compris entre 1,5 et 2,0.

Sur le plan physiopathologique, la MP est liée à une perte progressive des neurones dopaminergiques de la substance noire du mésencéphale. Cette dégénérescence provoque une réduction significative du taux de dopamine, neurotransmetteur essentiel au contrôle moteur. Lorsque la perte neuronale atteint environ 80 %, les premiers symptômes cliniques apparaissent. Les origines de cette neurodégénérescence restent encore floues, bien que des mutations génétiques, l'exposition à certains pesticides ou solvants industriels, ainsi que le vieillissement soient des facteurs de risque majeurs.

La maladie se caractérise principalement par des troubles moteurs : tremblements au repos, rigidité musculaire, bradykinésie (lenteur des mouvements), instabilité posturale et troubles de la marche. Ces symptômes présentent une variabilité interindividuelle importante, tant en termes d'intensité que de progression. D'autres manifestations plus précoces ou concomitantes, dites non motrices, incluent des troubles du sommeil, une perte d'odorat, une anxiété accrue, des troubles cognitifs voire des hallucinations à un

stade avancé.

1.2 Les défis du diagnostic précoce

Le diagnostic de la maladie de Parkinson (MP) demeure, encore aujourd’hui, un défi clinique majeur. Il repose essentiellement sur la reconnaissance d’un tableau symptomatique moteur — incluant la triade classique : akinésie, rigidité et tremblements de repos. Toutefois, cette approche diagnostique présente une limite physiopathologique critique : elle intervient à un stade où la neurodégénérescence des neurones dopaminergiques de la substance noire pars compacta est déjà avancée. Des études cliniques ont démontré qu’au moment de l’apparition des premiers signes moteurs visibles, une perte neuronale significative, allant de 60

Le diagnostic précoce se heurte néanmoins à plusieurs obstacles structurels. En premier lieu, la nature même de la MP est insidieuse, marquée par une évolution lente et une variabilité interindividuelle importante qui complique la standardisation des signes cliniques. Par ailleurs, la similitude des premiers symptômes avec ceux d’autres troubles neurodégénératifs ou liés au vieillissement naturel engendre des risques élevés de diagnostics erronés. Les échelles cliniques actuelles, bien qu’indispensables, manquent souvent de sensibilité pour détecter les altérations inframicroscopiques ou fonctionnelles qui précèdent les troubles moteurs macroscopiques.

Dans cette quête de biomarqueurs précoces, l’analyse des altérations de la parole suscite un intérêt croissant au sein de la communauté scientifique. Il est aujourd’hui admis que près de 70

C’est précisément dans ce contexte que l’intégration de systèmes d’aide à la décision médicale (MDSS) basés sur l’intelligence artificielle ouvre des perspectives novatrices. Les algorithmes d’apprentissage automatique permettent de s’affranchir des limites de l’observation humaine en modélisant des patterns complexes et multidimensionnels au sein des signaux vocaux. Le défi scientifique majeur réside désormais dans la conception de modèles de classification capables de garantir une haute sensibilité et une spécificité optimale. Cela exige une méthodologie rigoureuse de sélection des caractéristiques (feature selection) afin d’isoler, parmi une vaste gamme de paramètres acoustiques, les variables les plus discriminantes. Cette étape est cruciale pour éviter les phénomènes de redondance et de surapprentissage, permettant ainsi de construire des modèles prédictifs non seulement performants, mais également robustes et transposables à l’environnement clinique.

1.3 Apport de l'intelligence artificielle

L'essor de l'intelligence artificielle, et plus particulièrement des techniques d'apprentissage automatique (*Machine Learning*), a permis de considérables avancées dans le domaine médical. Ces techniques permettent de traiter de grands volumes de données, de détecter des motifs complexes et d'automatiser des tâches de diagnostic avec une précision croissante.

Dans le cas de la maladie de Parkinson, les données vocales des patients peuvent être analysées à l'aide de divers algorithmes de classification supervisée. Cependant, la qualité des résultats dépend fortement du choix des **caractéristiques** utilisées pour l'apprentissage. Il est donc nécessaire de mettre en œuvre des **méthodes de sélection de caractéristiques**, capables d'identifier les variables les plus pertinentes et de réduire la complexité des modèles.

Ce projet s'inscrit ainsi dans cette dynamique, en combinant des techniques de sélection de caractéristiques (filter-based, wrapper-based) avec plusieurs classifieurs (Naïve Bayes, SVM, KNN, MLP, Random Forest) afin d'améliorer la prédiction de la maladie.

Dans le cadre de ce projet, nous nous intéressons spécifiquement à l'analyse des caractéristiques vocales extraites d'un ensemble de données publiques, afin d'explorer le potentiel de différents algorithmes d'apprentissage pour la prédiction de la maladie de Parkinson.

Chapitre 2

État de l’art

2.1 Méthodes de diagnostic assisté par apprentissage automatique

La détection précoce et précise de la maladie de Parkinson a suscité un intérêt croissant pour l’application des techniques d’apprentissage automatique (*Machine Learning*). Ces méthodes permettent d’analyser des ensembles de données complexes pour en extraire des schémas diagnostiques pertinents, à partir de signaux vocaux, de données cliniques ou neurophysiologiques.

Les algorithmes les plus couramment utilisés dans ce domaine incluent les machines à vecteurs de support (SVM), les réseaux de neurones (dont les perceptrons multicouches ou MLP), le *Naïve Bayes*, les k-plus proches voisins (KNN), ainsi que les forêts aléatoires (RF). Leur efficacité dépend souvent du choix des caractéristiques utilisées en entrée, ce qui justifie l’usage combiné de techniques de sélection de variables (*feature selection*) pour améliorer la précision des modèles tout en limitant la redondance et la complexité.

2.2 Études récentes sur la prédiction de la maladie de Parkinson

Dans une étude fondatrice, Salvatore *et al.* ont utilisé une combinaison de l’analyse en composantes principales (PCA) pour réduire la dimensionnalité des données, et du classifieur SVM pour distinguer les patients atteints de Parkinson de ceux souffrant de paralysie supranucléaire progressive. Leur approche a permis d’atteindre une bonne précision en s’appuyant sur des données cliniques et démographiques.

Naranjo *et al.* ont proposé un système expert reposant sur des enregistrements vocaux de

80 patients, dont 50 % atteints de la maladie. Leur méthode, structurée en deux étapes (sélection de variables puis classification via LASSO), a montré une excellente capacité à différencier les patients malades à partir de caractéristiques acoustiques extraites de la parole.

Abdulhay *et al.* ont adopté une démarche originale basée sur l'extraction de caractéristiques de la démarche et des tremblements à partir des signaux vocaux. Après nettoyage du bruit, ils ont extrait des indicateurs temporels comme la durée des impulsions, obtenant une précision satisfaisante dans l'identification des cas de Parkinson.

De leur côté, Oh *et al.* ont exploré l'utilisation des réseaux de neurones convolutifs (CNN) appliqués à des signaux EEG. Leur modèle profond, composé de treize couches, a permis de classifier les signaux EEG de 20 patients avec des résultats prometteurs, bien qu'une validation sur un échantillon plus large soit nécessaire.

Mostafa *et al.* ont mené une étude comparative en utilisant un système multi-agents pour évaluer plusieurs méthodes de sélection de caractéristiques couplées à différents classifieurs (arbres de décision, *Naïve Bayes*, réseaux neuronaux, RF, SVM). Les résultats ont montré que le choix judicieux des variables améliore significativement la performance globale.

Enfin, d'autres travaux comme ceux de Haq, Salmanpour, Gao ou Li ont enrichi le domaine en combinant apprentissage supervisé, sélection automatique de variables (L1-norm SVM, méthodes hybrides) et données vocales ou cliniques. Ces approches ont permis d'atteindre des performances compétitives, parfois supérieures à 85 % de précision. Elles soulignent le potentiel des approches intelligentes dans la détection automatisée des troubles neurologiques.

2.3 Synthèse

La littérature met en évidence deux points majeurs :

- La pertinence des caractéristiques vocales comme indicateur précoce et non invasif de la maladie de Parkinson ;
- L'impact déterminant du choix de la méthode de sélection de caractéristiques sur les performances des modèles.

Ces observations motivent une étude approfondie des combinaisons optimales entre classifieurs (SVM, NB, KNN, MLP, RF) et techniques de sélection (*Information Gain*, PCA, *Best First*, *Greedy Stepwise*, PSO). Notre travail se positionne dans cette dynamique en évaluant expérimentalement différentes configurations afin d'identifier les stratégies les plus efficaces pour la prédiction de la MP à partir de données vocales.

Chapitre 3

Position du problème

3.1 Problématique générale

La maladie de Parkinson (MP) est un trouble neurodégénératif progressif, dont le diagnostic repose encore essentiellement sur l’observation clinique de symptômes moteurs. Malheureusement, ces symptômes n’apparaissent qu’à un stade avancé de la maladie, après une perte neuronale significative. Cela complique fortement le dépistage précoce, pourtant essentiel pour retarder la progression et améliorer la qualité de vie des patients.

Dans ce contexte, l’analyse des signaux vocaux a émergé comme une alternative prometteuse. Plusieurs études ont démontré que les caractéristiques acoustiques de la voix peuvent être affectées par la MP, même à un stade précoce. Cela a donné naissance à une approche basée sur l’intelligence artificielle : entraîner un modèle capable d’apprendre à reconnaître les signatures vocales spécifiques aux patients atteints.

3.2 Objectif du travail

L’objectif principal est de développer un système de prédiction automatique de la maladie de Parkinson, à partir d’un jeu de données constitué d’enregistrements vocaux annotés. Ce système devra être capable de :

- sélectionner automatiquement les caractéristiques les plus pertinentes (*features*) ;
- classer efficacement les enregistrements vocaux en deux classes : malade ou sain ;
- évaluer les performances de différentes combinaisons de méthodes de sélection de caractéristiques et d’algorithmes de classification.

3.3 Formulation du problème

Le problème posé se modélise comme une tâche de classification binaire supervisée, définie comme suit :

Soit un ensemble de données $\mathcal{D} = \{(X_i, y_i)\}_{i=1}^m$, où :

- $X_i \in \mathbb{R}^n$ est un vecteur de n caractéristiques acoustiques extraites d'un enregistrement vocal (ici $n = 46$) ;
- $y_i \in \{0, 1\}$ est la classe cible : 0 pour une personne saine, 1 pour une personne atteinte de MP.

L'objectif est d'apprendre une fonction $f : \mathbb{R}^n \rightarrow \{0, 1\}$ capable de prédire correctement y à partir de nouvelles observations X .

Pour améliorer la performance et la généralisation du modèle, un sous-ensemble de caractéristiques $S \subseteq \{x_1, x_2, \dots, x_n\}$ est sélectionné selon des critères spécifiques.

3.4 Méthodologie adoptée

La démarche repose sur quatre étapes principales :

1. Prétraitement des données

Les données sont nettoyées, normalisées, et les colonnes non pertinentes (identifiants, métadonnées) sont supprimées. Un encodage est éventuellement appliqué aux variables catégorielles.

2. Sélection de caractéristiques

Deux familles de méthodes sont utilisées :

- *Méthodes filter-based* : indépendantes du modèle d'apprentissage :
 - **Information Gain (IG)** : mesure la réduction d'entropie ;
 - **Principal Component Analysis (PCA)** : transforme les variables originales en composantes principales non corrélées.
- *Méthodes wrapper-based* : dépendent d'un classifieur pour évaluer chaque sous-ensemble de variables :
 - **Best First** : recherche récursive en profondeur ;
 - **Greedy Stepwise** : sélection progressive vers l'avant ou vers l'arrière ;
 - **PSO (Particle Swarm Optimization)** : algorithme d'optimisation inspiré des systèmes multi-agents.
- *Méthode hybride* :
 - **CfsSubsetEval** (Correlation-based Feature Subset Evaluation) : sélectionne des caractéristiques fortement corrélées à la classe cible mais faiblement

entre elles. Cette méthode est combinée avec des stratégies de recherche comme *Best First*, *Greedy Stepwise* ou *PSO*.

3. Classification

Les modèles sont entraînés à l'aide de plusieurs algorithmes supervisés :

- **Naïve Bayes (NB)** : classifieur probabiliste supposant l'indépendance conditionnelle ;
- **Support Vector Machine (SVM)** :
 - *c-SVM* : utilise un paramètre de pénalité C ;
 - *nu-SVM* : utilise un paramètre ν pour contrôler les exemples support.
- **K-Nearest Neighbor (KNN)** : classe selon la majorité des k voisins ;
- **Multilayer Perceptron (MLP)** : réseau de neurones à couches multiples ;
- **Random Forest (RF)** : ensemble d'arbres de décision entraînés sur des échantillons aléatoires.

4. Validation croisée

Une validation croisée à 10 plis est utilisée pour garantir une évaluation robuste et représentative.

3.5 Mesures de performance

Pour évaluer l'efficacité des différentes combinaisons (sélection + classifieur), plusieurs métriques classiques de classification supervisée sont utilisées :

- **Accuracy (exactitude)** :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Pourcentage de bonnes prédictions (positives et négatives) sur l'ensemble total.

- **Precision (précision)** :

$$\text{Precision} = \frac{TP}{TP + FP}$$

Proportion des prédictions positives qui sont réellement positives (fiabilité du diagnostic positif).

- **Recall (rappel ou sensibilité)** :

$$\text{Recall} = \frac{TP}{TP + FN}$$

Capacité du modèle à détecter les vrais cas de Parkinson.

- **F1-score** :

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Moyenne harmonique entre précision et rappel : utile en cas de classes déséquilibrées.

où :

- TP : vrais positifs,
- TN : vrais négatifs,
- FP : faux positifs,
- FN : faux négatifs.

3.6 Résumé de la démarche

La solution proposée consiste à explorer expérimentalement plusieurs pipelines de prédiction :

- en variant les méthodes de sélection de caractéristiques ;
- en testant divers classifieurs ;
- en évaluant les performances via des métriques rigoureuses.

L'objectif final est d'identifier la combinaison la plus performante pour la prédiction de la maladie de Parkinson à partir de données vocales. Cette étude se veut reproductible, comparative et guidée par la recherche d'un compromis entre précision, robustesse et simplicité du modèle.

Chapitre 4

Méthodologie de résolution

4.1 Jeu de données

Le jeu de données utilisé provient du *UCI Machine Learning Repository* et contient 240 enregistrements vocaux de 80 patients (50 % atteints de la maladie de Parkinson). Chaque enregistrement est représenté par 46 caractéristiques acoustiques extraites de signaux vocaux. L'objectif est de construire un modèle prédictif permettant de déterminer si un individu est atteint ou non à partir de ces caractéristiques.

4.2 Prétraitement

Le prétraitement constitue une étape essentielle dans tout pipeline d'apprentissage automatique. Il vise à préparer les données en vue d'un apprentissage optimal des modèles, en corrigeant les déséquilibres, en réduisant la dimensionnalité et en assurant la cohérence statistique des variables.

1. Normalisation et transformation Deux méthodes de normalisation ont été utilisées successivement :

- **StandardScaler** : standardise chaque variable pour qu'elle ait une moyenne nulle et un écart type de 1 :

$$X' = \frac{X - \mu}{\sigma}$$

Cela rend les variables comparables, ce qui est indispensable pour les méthodes sensibles à l'échelle (comme SVM ou KNN).

- **PowerTransformer (méthode de Yeo-Johnson)** : applique une transformation non linéaire qui stabilise la variance et rend les données plus gaussiennes. Cela peut améliorer la robustesse des modèles linéaires ou des MLP.

Le prétraitement est appliqué à toutes les caractéristiques numériques, à l'exception de l'étiquette cible **Status**.

2. Sélection de caractéristiques (Feature Selection) Le jeu de données contient initialement **46 caractéristiques** extraites de la voix. Certaines d'entre elles peuvent être redondantes, peu informatives ou fortement corrélées entre elles. Pour améliorer l'efficacité et la précision des classifieurs, différentes techniques de réduction de dimension ont été appliquées.

Les méthodes utilisées se répartissent en trois grandes familles :

a) Méthodes filter-based Ces méthodes évaluent chaque caractéristique indépendamment du classifieur selon un critère statistique.

Information Gain (IG) : mesure l'apport d'information d'une variable sur la classe cible (basé sur la réduction d'entropie).

Principal Component Analysis (PCA) : transforme les données en un nouvel espace orthogonal, en conservant les composantes expliquant le plus de variance.

b) Méthodes wrapper-based Ces approches évaluent directement l'impact d'un sous-ensemble de caractéristiques sur la performance d'un classifieur donné.

Best First : recherche récursive des meilleurs sous-ensembles en élargissant progressivement l'espace de recherche.

Greedy Stepwise : sélection gloutonne, ajoutant ou retirant une variable à chaque itération.

Particle Swarm Optimization (PSO) : méthode d'optimisation inspirée du comportement collectif (comme les essaims), utilisée pour explorer efficacement l'espace des sous-ensembles de variables.

c) Méthode corrélationnelle : CfsSubsetEval CfsSubsetEval (Correlation-based Feature Subset Selection) : sélectionne les variables qui sont fortement corrélées à la classe cible, mais faiblement corrélées entre elles. Elle équilibre la pertinence et la non-redondance, ce qui la rend particulièrement adaptée aux données vocales, souvent fortement corrélées.




FIGURE 4.1 – Filter-based Approach vs. Wrapper-based Approach

4.3 Modélisation : algorithmes de classification

Dans le cadre de ce projet, la prédiction de la maladie de Parkinson à partir de caractéristiques vocales est modélisée comme une tâche de classification binaire supervisée. L'objectif est de prédire une étiquette $y \in \{0, 1\}$ indiquant si un patient est atteint (1) ou non (0) de la maladie, à partir d'un vecteur de caractéristiques acoustiques $X \in \mathbb{R}^n$.

Pour cette tâche, plusieurs algorithmes de classification ont été étudiés. Chacun repose sur des fondements mathématiques et une logique d'apprentissage différents. Voici une explication détaillée de chacun.

1. Naïve Bayes (NB) Le classifieur Naïve Bayes est basé sur le théorème de Bayes :

$$P(y | X) = \frac{P(X | y) \cdot P(y)}{P(X)}$$

Il calcule la probabilité que X appartienne à chaque classe y et prédit la classe ayant

la probabilité maximale. L'hypothèse dite « naïve » suppose que les variables x_i sont conditionnellement indépendantes entre elles, ce qui simplifie le calcul :

$$P(X | y) = \prod_{i=1}^n P(x_i | y)$$

Malgré cette hypothèse forte, ce modèle est rapide, robuste, et souvent très performant sur des jeux de données bruités ou de petite taille.

2. Support Vector Machine (SVM) Le SVM cherche à trouver un hyperplan qui sépare au mieux les deux classes, en maximisant la marge entre les points des deux catégories. Formellement.

Si les données ne sont pas linéairement séparables, le SVM utilise des noyaux (*kernel*) pour projeter les données dans un espace de plus grande dimension où elles deviennent séparables. Dans ce projet, on utilise le noyau RBF (radial basis function) .

Deux variantes sont utilisées :

- **c-SVM** : introduit un paramètre C qui contrôle la pénalité associée aux erreurs de classification ;
- **nu-SVM** : remplace C par un paramètre $\nu \in [0, 1]$ qui contrôle le nombre de vecteurs de support et le taux d'erreurs.




FIGURE 4.2 – SVM illustration

3. K-Nearest Neighbor (KNN) Le KNN est une méthode simple mais efficace. Il classe une nouvelle observation en fonction de la majorité des k observations les plus proches dans l'espace des caractéristiques, selon une distance (typiquement euclidienne) :

$$d(x, x') = \sum_{i=1}^n (x_i - x'_i)^2$$

Aucune phase d'apprentissage n'est nécessaire : le modèle conserve toutes les données d'entraînement. Le choix de k est crucial : une valeur trop faible rend le modèle sensible

au bruit, tandis qu'une valeur trop élevée peut inclure des voisins d'une autre classe.




FIGURE 4.3 – K-NN Model

4. Multilayer Perceptron (MLP) Le MLP est un réseau de neurones artificiels composé de plusieurs couches :

- Une couche d'entrée recevant les caractéristiques ;
- Une ou plusieurs couches cachées avec des fonctions d'activation non linéaires (par exemple ReLU) ;
- Une couche de sortie fournissant la prédiction finale (probabilité d'appartenance à la classe 1).

où σ est une fonction d'activation (ex. : ReLU , w_i sont les poids et b est le biais.

L'apprentissage s'effectue par descente de gradient et rétropropagation de l'erreur, en minimisant une fonction de coût (comme l'entropie croisée).




FIGURE 4.4 – MLP Model

5. Random Forest (RF) Le Random Forest est un algorithme d'ensemble qui combine plusieurs arbres de décision. Son fonctionnement repose sur :

- L'entraînement de chaque arbre sur un sous-échantillon aléatoire du jeu de données (bagging) ;

- La sélection aléatoire d'un sous-ensemble de variables à chaque nœud pour la division ;
- Une prédiction finale faite par vote majoritaire de l'ensemble des arbres.

Les RF sont robustes au surapprentissage, aux données bruitées et aux variables corrélées. Ils permettent de capturer des interactions complexes entre les variables, sans nécessiter de réglages complexes.

Input:
D' , a set of d training sets;
D'' , a set of d test sets;
k , number of models in the ensemble;
f , number of attributes that are used to split the D'
M_i , set of <i>base classifiers</i> .

Output:
The ensemble (a composite model M^*)

Steps:
(1) for $i = 1$ to k do
(2) - create bootstrap sample of D' with replacement, D_i ;
(3) - construct a decision tree classifier by selecting randomly the attributes f ;
(4) - use CART method to grow the trees.
(5) end for
//To use the ensemble for classifying data on test set:
(1) each of the k models (decision tree) classifies D'' and return the majority vote

FIGURE 4.5 – Pseudo-code of RF model

4.3.1 Environnement d'implémentation

Le projet a été développé en **Python 3.12** à l'aide de plusieurs bibliothèques spécialisées pour le traitement des données, l'apprentissage automatique, la visualisation, et l'optimisation. Les principales bibliothèques utilisées sont :

- **pandas**, **numpy** : pour la manipulation de données tabulaires et le calcul numérique ;
- **scikit-learn** : pour les algorithmes de classification, la validation croisée, la normalisation, la sélection de caractéristiques et les métriques d'évaluation ;
- **matplotlib**, **seaborn** : pour la visualisation des résultats (matrices de confusion, courbes d'apprentissage, etc.) ;
- **pyswarms** : pour l'implémentation de l'algorithme d'optimisation par essaim particulaire (PSO) dans le cadre de la sélection de caractéristiques ;

- `scipy`, `joblib` : pour les outils mathématiques avancés et la sérialisation des modèles.

4.4 Choix des hyperparamètres

Les hyperparamètres des classifieurs utilisés dans ce projet ont été sélectionnés par validation croisée, dans le but de maximiser la performance tout en évitant le surapprentissage. Voici les paramètres retenus et la justification de chaque choix.

K-Nearest Neighbor (KNN) $k = 5$: ce choix correspond à une valeur couramment utilisée dans la littérature. Un k trop petit (ex. : 1) rendrait le modèle trop sensible au bruit local et aux valeurs aberrantes. Un k trop grand dilue les décisions locales. $k = 5$ représente donc un compromis entre biais et variance. Il permet de lisser les décisions sans perdre trop de finesse locale.

Support Vector Machine (SVM) Deux variantes ont été testées :

- **c-SVM** :
 - $C = 1$: ce paramètre contrôle la pénalité d'erreur. Une petite valeur de C autorise davantage de violations de la marge (i.e. erreurs de classification), ce qui améliore la généralisation du modèle.
 - $Kernel = RBF$: le noyau RBF (*Radial Basis Function*) est un noyau non linéaire qui projette les données dans un espace de dimension supérieure pour les rendre séparables. Il est adapté à des données complexes comme les caractéristiques vocales.
- **nu-SVM** :
 - $\nu = 0.5$: ce paramètre permet de contrôler la proportion maximale de points marginaux et la proportion minimale de vecteurs de support. $\nu = 0.5$ offre un équilibre entre souplesse et contrainte sur la frontière de décision, adapté à des jeux de données bruités.

Multilayer Perceptron (MLP)

- **Architecture** : (50, 50) — le réseau est constitué de deux couches cachées de 50 neurones chacune. Cette structure permet de modéliser des relations non linéaires complexes tout en limitant la surcapacité. Le choix est empirique, mais souvent efficace sur des données de moyenne dimension.
- **Fonction d'activation** : ReLU — la fonction Rectified Linear Unit ($\text{ReLU}(x) = \max(0, x)$) est couramment utilisée car elle permet de conserver les gradients positifs, réduit les problèmes de saturation et accélère l'apprentissage.

- **Optimiseur** : Adam — il combine les avantages d'AdaGrad et RMSProp. Il ajuste automatiquement le taux d'apprentissage pour chaque poids, ce qui améliore la vitesse de convergence et la stabilité du réseau.
- **Epochs** = 1000 avec **warm_start** — cela permet un entraînement progressif du réseau, où les poids sont conservés entre les itérations, facilitant l'analyse de convergence (utile pour tracer les courbes d'évolution de l'accuracy).

Random Forest (RF)

- **Nombre d'arbres** = 100 — un nombre suffisamment grand pour réduire la variance du modèle et garantir une meilleure robustesse sans surcharger le calcul ;
- **Critère** = Gini — mesure l'impureté d'un nœud. Plus simple et plus rapide à calculer que l'entropie, il donne des résultats similaires dans la majorité des cas ;
- **Profondeur max non spécifiée** — la profondeur est laissée en optimisation automatique (jusqu'à ce que les feuilles soient pures ou contiennent moins de deux échantillons), ce qui permet d'adapter la complexité du modèle aux données.

Particle Swarm Optimization (PSO) Utilisé ici dans le cadre de la sélection de caractéristiques (*wrapper-based*), PSO simule le comportement collectif de particules dans l'espace de recherche. Les hyperparamètres ont été choisis comme suit :

- **Nombre de particules** = 20 — nombre modéré assurant une exploration efficace de l'espace sans surcharge computationnelle ;
- **Itérations** = 30 — nombre suffisant pour assurer la convergence du nuage de particules vers une solution stable ;
- **Paramètres d'inertie et d'accélération** :
 - $c_1 = 2$, $c_2 = 2$: coefficients d'attraction personnelle et sociale. Cela signifie que chaque particule est attirée autant par sa meilleure position connue que par celle de ses voisines ;
 - $w = 0.9$: coefficient d'inertie, favorise l'exploration au début de la recherche. Une valeur élevée permet de parcourir largement l'espace des solutions.

4.5 Pipeline de traitement

Le pipeline de traitement comprend les étapes suivantes :

1. **Prétraitement** :
 - Standardisation via `StandardScaler` ;
 - Transformation via `PowerTransformer`.
2. **Sélection de caractéristiques** :

- Méthodes filter-based : Information Gain, PCA ;
- Méthodes wrapper-based : Greedy Stepwise, Best First, PSO ;
- Méthode corrélationnelle : `CfsSubsetEval`.

3. **Entraînement des modèles :**

- Utilisation des classifieurs après sélection optimale des variables.

4. **Validation croisée :**

- Validation à 10 plis pour chaque combinaison sélection + classifieur.

5. **Évaluation :**

- Métriques : Accuracy, Precision, Recall, F1-score.

4.6 Espaces de résultats et visualisations

Afin d'évaluer et d'interpréter les performances des différents modèles de classification, plusieurs types de visualisations ont été générés. Ces représentations graphiques permettent à la fois d'analyser la qualité des prédictions, de comparer les performances entre classifieurs, et de mieux comprendre les relations entre les variables.

- **Matrices de confusion** : Ces matrices illustrent la distribution des prédictions du modèle par rapport aux vraies classes.
- **Graphiques comparatifs (barplots)** : Des diagrammes en barres sont utilisés pour comparer les performances globales des classifieurs selon plusieurs métriques : *Accuracy*, *Recall*, *F1-score*. Chaque barre représente un score moyen obtenu lors de la validation croisée à 10 plis.
- **Matrice de corrélation des variables** : Elle permet de détecter les variables fortement corrélées, qui peuvent être éliminées ou combinées pour améliorer l'apprentissage. Cette analyse est particulièrement utile avant d'appliquer des méthodes de sélection de caractéristiques comme `CfsSubsetEval` ou PCA.

Chapitre 5

Méthodologie de validation des résultats numériques

5.1 Jeu de données utilisé

Les expériences menées s'appuient sur la base de données publique UCI Parkinson, qui contient un total de 240 enregistrements vocaux issus de 80 patients, avec pour chacun trois répliques de prise de son. Chacun de ces enregistrements est décrit par 46 variables acoustiques, extraites automatiquement. Cette base de données est équilibrée en termes de genre et de classe (patients atteints ou non de la maladie de Parkinson).

5.2 Protocole expérimental

Les expériences ont été menées à l'aide d'une validation croisée à 10 plis, garantissant une évaluation robuste des performances des classifieurs. Les métriques utilisées pour évaluer chaque modèle sont les suivantes :

- **Accuracy (Exactitude)** : proportion des prédictions correctes.
- **Precision (Précision)** : capacité à ne pas classer à tort un patient sain comme malade.
- **Recall (Rappel)** : capacité à détecter correctement les patients atteints de la maladie.
- **F1-score** : moyenne harmonique entre la précision et le rappel.

5.3 Analyse de la matrice de corrélation

La matrice de corrélation entre les variables du jeu de données met en évidence plusieurs observations importantes concernant les relations linéaires entre les caractéristiques

acoustiques et la variable cible **Status** :

- **Corrélation avec la classe Status** : Plusieurs variables, notamment les indicateurs de jitter (**Jitter_rel**, **Jitter_abs**, **Jitter_RAP**, **Jitter_PPQ**) et de shimmer (**Shim_loc**, **Shim_dB**), présentent une corrélation positive significative avec la variable cible. Cela suggère qu’elles sont potentiellement discriminantes entre les patients sains et ceux atteints de la maladie de Parkinson.
- **Présence de redondance (multicolinéarité)** : Des blocs de forte corrélation sont observés entre :
 - les variables **Jitter_***, qui sont fortement redondantes entre elles ;
 - les variables **Shim_***, également très corrélées entre elles ;
 - les coefficients **MFCC0** à **MFCC12** et **Delta0** à **Delta12**, qui montrent une structure hautement corrélée.Cela indique une duplication d’information, ce qui peut nuire à certains modèles. Ces groupes peuvent être compressés (par exemple avec PCA) ou filtrés lors de la sélection de caractéristiques.
- **Variables peu informatives** : Certaines variables, comme **Gender_1**, montrent une faible corrélation avec la variable **Status**. Elles sont donc peu pertinentes dans la tâche de classification et peuvent être exclues lors de la phase de sélection.
- **Intérêt pour la sélection de variables** : Cette matrice est particulièrement utile pour guider des méthodes de sélection comme **CfsSubsetEval**, **Information Gain** ou l’analyse en composantes principales (PCA), en identifiant les variables pertinentes tout en réduisant la redondance.

Ainsi, cette analyse préliminaire confirme que certaines familles de variables (notamment les mesures de jitter, shimmer, et MFCC) sont corrélées avec la maladie et justifie le recours à des techniques de réduction de dimension ou de sélection de caractéristiques pour optimiser les performances des classifieurs.




FIGURE 5.1 – Matrice de corrélation

5.4 Types de simulations réalisées


Trois types de simulations ont été réalisés pour comparer les approches :

5.4.1 Sans sélection de caractéristiques

Dans cette configuration de base, les classifieurs ont été entraînés à l'aide de la totalité des 46 variables. Cette simulation constitue un point de référence pour mesurer l'impact des techniques de sélection de caractéristiques.

TABLE 5.1 – Performances des classifieurs sans sélection de caractéristiques

Classifier	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8208	0.8739	0.8000	0.8130
SVM (C-SVM)	0.8000	0.8593	0.7667	0.7860
SVM (nu-SVM)	0.7917	0.8367	0.7667	0.7763
MLP	0.7167	0.7563	0.7000	0.6982
KNN	0.7792	0.8145	0.7583	0.7609
Random Forest	0.7708	0.7999	0.7500	0.7527



5.4.2 Avec sélection de caractéristiques basée sur des méthodes *filter-based*

Les méthodes *filter-based* évaluent la pertinence des variables indépendamment des modèles de classification. Les techniques utilisées incluent :

- **Information Gain (IG)** ;

TABLE 5.2 – Résultats avec Information Gain + Validation croisée (10 folds)

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8000	0.8051	0.7917	0.7983
SVM (C-SVM)	0.8000	0.7951	0.8083	0.8017
SVM (nu-SVM)	0.8042	0.7967	0.8167	0.8066
MLP	0.7583	0.7246	0.8333	0.7752
KNN	0.7667	0.7963	0.7167	0.7544
Random Forest	0.7792	0.7863	0.7667	0.7764

— Analyse en Composantes Principales (PCA) ;


TABLE 5.3 – Résultats avec PCA + Validation croisée (10 folds)

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.7542	0.7961	0.6833	0.7354
SVM (C-SVM)	0.8292	0.8496	0.8000	0.8240
SVM (nu-SVM)	0.8417	0.8475	0.8333	0.8403
MLP	0.7167	0.6711	0.8500	0.7500
KNN	0.8000	0.8273	0.7583	0.7913
Random Forest	0.8250	0.8362	0.8083	0.8220

— CfsSubsetEval avec les recherches *Best First* et *Greedy Stepwise* et *PSO*.

TABLE 5.4 – Résultats avec CfsSubsetEval + Best First


Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8000	0.8270	0.7917	0.7858
SVM (C-SVM)	0.7833	0.7956	0.7917	0.7750
SVM (nu-SVM)	0.8000	0.8004	0.8250	0.7921
MLP	0.7625	0.7971	0.7333	0.7433
KNN	0.7583	0.7796	0.7500	0.7456
Random Forest	0.7667	0.7933	0.7417	0.7419



— Méthode : Greedy Stepwise

TABLE 5.5 – Résultats avec CfsSubsetEval + Greedy Stepwise

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8125	0.8253	0.8167	0.8000
SVM (C-SVM)	0.7792	0.8316	0.7417	0.7567
SVM (nu-SVM)	0.7917	0.8430	0.7583	0.7720
MLP	0.7417	0.7714	0.7417	0.7307
KNN	0.7750	0.8095	0.7667	0.7679
Random Forest	0.8000	0.8289	0.7750	0.7814



— Méthode : PSO

TABLE 5.6 – Résultats avec CfsSubsetEval + PSO

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8125	0.8253	0.8167	0.8000
SVM (C-SVM)	0.7792	0.8316	0.7417	0.7567
SVM (nu-SVM)	0.7917	0.8430	0.7583	0.7720
MLP	0.7417	0.7714	0.7417	0.7307
KNN	0.7750	0.8095	0.7667	0.7679
Random Forest	0.8000	0.8289	0.7750	0.7814

5.4.3 Avec sélection de caractéristiques basée sur des méthodes *wrapper-based*

Les méthodes *wrapper-based* intègrent le classifieur dans le processus de sélection. Les stratégies de recherche utilisées incluent :

TABLE 5.7 – Performance des Classifieurs avec Wrapper-based (First Best, base=Naïve Bayes)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.837500	0.858407	0.808333	0.832618
c-SVM	0.841667	0.859649	0.816667	0.837607
nu-SVM	0.845833	0.873874	0.808333	0.839827
MLP	0.812500	0.809917	0.816667	0.813278
KNN	0.841667	0.853448	0.825000	0.838983
Random Forest	0.816667	0.845455	0.775000	0.808696

TABLE 5.8 – Résultats avec Wrapper-based (Greedy Stepwise, base = Naïve Bayes)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.837500	0.871560	0.791667	0.829694
c-SVM	0.825000	0.848214	0.791667	0.818966
nu-SVM	0.825000	0.842105	0.800000	0.820513
MLP	0.762500	0.773913	0.741667	0.757447
KNN	0.783333	0.769841	0.808333	0.788618
Random Forest	0.795833	0.819820	0.758333	0.787879

TABLE 5.9 – Résultats avec Wrapper PSO (base = Naïve Bayes pour sélection des features)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.829167	0.843478	0.808333	0.825532
c-SVM	0.825000	0.842105	0.800000	0.820513
nu-SVM	0.829167	0.837607	0.816667	0.827004
MLP	0.820833	0.834783	0.800000	0.817021
KNN	0.854167	0.851240	0.858333	0.854772
Random Forest	0.812500	0.820513	0.800000	0.810127

TABLE 5.10 – Résumé des performances FIRST BEST WRAPPED (BASE = CSVM, Validation croisée 10-fold)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.795833	0.881720	0.683333	0.769953
c-SVM	0.845833	0.887850	0.791667	0.837004
nu-SVM	0.841667	0.879630	0.791667	0.833333
MLP	0.787500	0.800000	0.766667	0.782979
KNN	0.800000	0.815789	0.775000	0.794872
Random Forest	0.808333	0.836364	0.766667	0.800000

TABLE 5.11 – Résumé des performances wrapped greedy stepwise (base = SVM, Validation croisée 10-fold)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.825000	0.830508	0.816667	0.823529
c-SVM	0.841667	0.872727	0.800000	0.834783
nu-SVM	0.837500	0.852174	0.816667	0.834043
MLP	0.808333	0.808333	0.808333	0.808333
KNN	0.850000	0.850000	0.850000	0.850000
Random Forest	0.812500	0.820513	0.800000	0.810127

TABLE 5.12 – Résumé des performances (PSO avec c-SVM pour sélection des features)

Model	Accuracy	Precision	Recall	F1-Score
Naïve Bayes	0.812500	0.820513	0.800000	0.810127
c-SVM	0.841667	0.853448	0.825000	0.838983
nu-SVM	0.837500	0.840336	0.833333	0.836820
MLP	0.783333	0.793103	0.766667	0.779661
KNN	0.829167	0.837607	0.816667	0.827004
Random Forest	0.804167	0.817391	0.783333	0.800000

TABLE 5.13 – Performance des Classifieurs - Wrapper First Best (NuSVM indirect)

Classifier	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.825	0.831	0.817	0.824
c-SVM	0.825	0.855	0.783	0.817
nu-SVM	0.838	0.858	0.808	0.833
MLP	0.787	0.805	0.758	0.781
KNN	0.808	0.819	0.792	0.805
Random Forest	0.812	0.844	0.767	0.803

TABLE 5.14 – Performance des Classifieurs - Wrapper Greedy StepWise (NuSVM indirect)

Classifier	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.812	0.815	0.808	0.812
c-SVM	0.833	0.851	0.808	0.829
nu-SVM	0.833	0.839	0.825	0.832
MLP	0.783	0.788	0.775	0.782
KNN	0.821	0.829	0.808	0.819
Random Forest	0.812	0.844	0.767	0.803

TABLE 5.15 – Performance des Classifieurs - Wrapper PSO (NuSVM)

Classifier	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.833	0.845	0.817	0.831
c-SVM	0.854	0.876	0.825	0.850
nu-SVM	0.854	0.883	0.817	0.848
MLP	0.779	0.782	0.775	0.778
KNN	0.850	0.862	0.833	0.847
Random Forest	0.808	0.825	0.783	0.803

TABLE 5.16 – Résultats avec Wrapper-Based (MLP base) + First Best

Classifier	Accuracy	Precision	Recall	F-score
Naïve Bayes	0.837500	0.858407	0.808333	0.832618
c-SVM	0.820833	0.840708	0.791667	0.815451
nu-SVM	0.820833	0.823529	0.816667	0.820084
MLP	0.825000	0.819672	0.833333	0.826446
KNN	0.825000	0.825000	0.825000	0.825000
Random Forest	0.804167	0.823009	0.775000	0.798283

TABLE 5.17 – Résultats avec Wrapper-Based (MLP base) + Greedy StepWise

Classifier	Accuracy	Precision	Recall	F-score
Naïve Bayes	0.787500	0.810811	0.750000	0.779221
c-SVM	0.820833	0.846847	0.783333	0.813853
nu-SVM	0.816667	0.827586	0.800000	0.813559
MLP	0.783333	0.783333	0.783333	0.783333
KNN	0.812500	0.820513	0.800000	0.810127
Random Forest	0.808333	0.830357	0.775000	0.801724

TABLE 5.18 – Performance des classifieurs avec PSO + MLP

Classifier	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.825000	0.843970	0.825000	0.819564
C-SVM	0.808333	0.824683	0.808333	0.803036
Nu-SVM	0.804167	0.821201	0.804167	0.798775
MLP	0.804167	0.829071	0.804167	0.798399
K-NN	0.783333	0.794516	0.783333	0.778193
Random Forest	0.791667	0.807628	0.791667	0.781682

TABLE 5.19 – Résultats moyens (10-fold CV) avec Wrapper-based (KNN, First Best)

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.779167	0.890823	0.650000	0.739663
c-SVM	0.812500	0.846956	0.775000	0.801828
nu-SVM	0.808333	0.838774	0.775000	0.798271
MLP	0.754167	0.771494	0.741667	0.747958
KNN	0.800000	0.824036	0.791667	0.799289
Random Forest	0.783333	0.829960	0.741667	0.773511




TABLE 5.20 – Résultats moyens (10-fold CV) avec Wrapper-based (KNN, Greed Step-Wise)

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.820833	0.841017	0.808333	0.815984
c-SVM	0.837500	0.860730	0.816667	0.832187
nu-SVM	0.837500	0.861971	0.816667	0.833049
MLP	0.808333	0.824231	0.791667	0.799937
KNN	0.837500	0.872484	0.800000	0.829902
Random Forest	0.800000	0.820533	0.783333	0.796932




TABLE 5.21 – Résultats avec Wrapper-based PSO (base KNN)

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.816667	0.845206	0.783333	0.809148
c-SVM	0.825000	0.839700	0.816667	0.820299
nu-SVM	0.837500	0.847523	0.833333	0.834946
MLP	0.779167	0.782991	0.783333	0.779490
KNN	0.850000	0.860638	0.841667	0.847357
Random Forest	0.800000	0.837109	0.758333	0.789815

TABLE 5.22 – Résultats sans sélection de caractéristiques

Model	Accuracy	Precision	Recall	F1-score
Naïve Bayes	0.8208	0.8739	0.8000	0.8130
SVM (C-SVM)	0.8000	0.8593	0.7667	0.7860
SVM (nu-SVM)	0.7917	0.8367	0.7667	0.7763
MLP	0.7167	0.7563	0.7000	0.6982
KNN	0.7792	0.8145	0.7583	0.7609
Random Forest	0.7708	0.7999	0.7500	0.7527

5.5 Comparaison et évaluation des performances

Les résultats des simulations ont été comparés à ceux présentés dans l'article de référence.

La comparaison repose sur plusieurs tableaux et représentations visuelles :

5.5.1 Tableaux comparatifs

Un ensemble de tableaux a été généré pour résumer les performances obtenues :

— performances avec méthodes *filter-based* ;

TABLE 5.23 – Récapitulatif de la précision des classifieurs avec des méthodes de sélection de caractéristiques basées sur des filtres

Classifieur	Précision (Avant FS)	Meilleure Précision (Avec FS)	Méthode
Naïve Bayes	0.8208	0.8125	Greedy Stepwise / PSO
SVM (C-SVM)	0.8000	0.8292	PCA
SVM (nu-SVM)	0.7917	0.8417	PCA
MLP	0.7167	0.7625	CfsSubsetEval
KNN	0.7792	0.8000	PCA
Random Forest	0.7708	0.8250	PCA

— performances avec méthodes *wrapper-based*, pour chaque classifieur de base.

TABLE 5.24 – Meilleurs résultats pour les techniques basées sur les wrappers

Classifieur	Précision (Avant FS)	Meilleure Précision (Avec FS)	Méthode (Classifieur de Base)
Naïve Bayes	0.8208	0.8375	First Best (Naïve Bayes) / First Best (MLP)
SVM (C-SVM)	0.8000	0.8542	PSO (Nu-SVM)
SVM (nu-SVM)	0.7917	0.8542	PSO (Nu-SVM) / PSO (KNN)
MLP	0.7167	0.8250	First Best (MLP)
KNN	0.7792	0.8542	PSO (Naïve Bayes)
Random Forest	0.7708	0.8292	PSO (KNN)

TABLE 5.25 – Comparaison entre les techniques basées sur les filtres et les wrappers

Classifieur	Préc. (Avant FS)	Meilleure Préc. (Filtre)	Méthode de Filtre	Meilleure Préc. (Wrapper)	Méthode Wrapper (Base)
Naïve Bayes	0.8208	0.8125	Greedy Step-wise / PSO	0.8375	First Best (NB/MLP)
SVM (C-SVM)	0.8000	0.8292	PCA	0.8542	PSO (Nu-SVM)
SVM (nu-SVM)	0.7917	0.8417	PCA	0.8542	PSO (Nu-SVM/KNN)
MLP	0.7167	0.7625	CfsSubsetEval	0.8250	First Best (MLP)
KNN	0.7792	0.8000	PCA	0.8542	PSO (Naïve Bayes)
Random Forest	0.7708	0.8250	PCA	0.8292	PSO (KNN)




FIGURE 5.2 – comparaisons

5.6 Analyse des résultats

5.6.1 Interprétation

L'analyse des résultats montre une nette amélioration des performances des classifieurs après application de techniques de sélection de caractéristiques. En particulier, les méthodes *wrapper-based* surpassent généralement les approches *filter-based*, notamment lorsqu'elles sont associées à un algorithme d'optimisation comme le PSO.

Parmi tous les classifieurs testés, **KNN** et **nu-SVM** sont ceux ayant obtenu les meilleurs taux de précision après sélection de variables avec **PSO**. Par exemple, KNN atteint une précision de **85.42%** avec PSO basé sur les attributs sélectionnés via Nu-SVM, contre 77.92% sans sélection. De même, nu-SVM atteint jusqu'à **85.42%** avec PSO.

En revanche, certains modèles comme le **MLP** présentent des performances plus modestes malgré la sélection de caractéristiques. Cela peut être dû à leur sensibilité aux hyperparamètres ou à un surapprentissage sur des jeux de données de petite taille comme celui-ci.

Les techniques *filter-based* telles que **PCA** améliorent aussi significativement les performances, surtout pour les SVM et les arbres aléatoires. Cela s'explique par la capacité du PCA à éliminer les redondances tout en préservant l'information.

5.6.2 Discussion sur les performances

- **Sans sélection de caractéristiques** : Bien que certains modèles obtiennent de bonnes performances, l'utilisation des 46 variables introduit de la redondance et peut nuire à la généralisation.
- **Filter-based** : Ces méthodes sont simples et rapides, et donnent des résultats intéressants. Par exemple, la combinaison *PCA + nu-SVM* fournit une précision de **84.17%**, ce qui est supérieur à la configuration sans sélection.
- **Wrapper-based** : Ces approches montrent la meilleure efficacité. En particulier :
 - **PSO + KNN** : combinaison la plus performante (précision de **85.42%**) ;
 - **PSO + nu-SVM** : également très compétitif avec une précision similaire ;
 - **Greedy Stepwise + nu-SVM** : donne aussi de très bons résultats (précision de **83.75%**).
- **Impact du classifieur de base dans les wrappers** : Le choix du classifieur utilisé pour guider la sélection des variables influence fortement les résultats finaux. Nu-SVM et KNN semblent les plus adaptés dans ce rôle.
- **Équilibre entre performances et coût computationnel** : Les méthodes basées sur PSO sont les plus performantes, mais elles sont également plus coûteuses en temps de calcul. Pour des systèmes à déploiement rapide ou sur de grandes bases de données, les méthodes *filter-based* peuvent être préférées.
- **Robustesse et reproductibilité** : La validation croisée à 10 plis a permis de garantir que les résultats ne dépendent pas d'un seul découpage du jeu de données, ce qui renforce la validité des conclusions.

En conclusion, cette étude montre que l'association judicieuse d'une méthode de sélection de caractéristiques et d'un classifieur permet d'améliorer significativement les performances de prédiction de la maladie de Parkinson à partir de signaux vocaux. Le recours à des techniques comme PSO offre un excellent compromis entre pertinence des variables

et performances globales.

Conclusion Générale

Voici une version enrichie et détaillée de votre conclusion, conçue pour donner davantage de profondeur académique à votre travail tout en préservant scrupuleusement l'intégralité de vos résultats chiffrés et de vos choix méthodologiques.

Conclusion Générale Ce projet de recherche s'est articulé autour d'une problématique centrale : l'exploitation des techniques d'apprentissage automatique (Machine Learning) pour optimiser le diagnostic prédictif de la maladie de Parkinson (MP) par l'analyse de biomarqueurs vocaux. En nous appuyant sur un jeu de données issu de l'UCI Machine Learning Repository, constitué de 240 enregistrements vocaux caractérisés par 46 attributs acoustiques distincts, nous avons conduit une expérimentation systématique visant à évaluer l'impact des stratégies de sélection de caractéristiques sur la précision des modèles de classification.

Pour répondre aux défis liés à la dimensionnalité des données et à la redondance des mesures acoustiques — telles que les indices de jitter et de shimmer —, nous avons comparé rigoureusement plusieurs approches. Cette méthodologie a intégré des méthodes de pré-traitement avancées, couplées à des techniques de sélection de caractéristiques réparties en deux catégories : les méthodes filter-based et wrapper-based. Ces variables ont ensuite été soumises à divers classifieurs supervisés, incluant les algorithmes Naïve Bayes (NB), Support Vector Machine (SVM), K-Nearest Neighbor (KNN), Multilayer Perceptron (MLP) et Random Forest (RF).

Les résultats expérimentaux obtenus confirment la haute pertinence de l'intelligence artificielle pour la détection non invasive de la MP. Ils démontrent, de manière significative, que la performance diagnostique est intrinsèquement liée à la qualité de la sélection des variables en amont de la classification. Les méthodes de type wrapper-based, et plus spécifiquement l'algorithme d'optimisation par essaim particulaire (PSO), se sont distinguées par leur supériorité, surpassant systématiquement les approches filter-based.

Au terme de notre analyse comparative, les performances les plus élevées ont été atteintes par deux combinaisons principales, affichant toutes deux une précision remarquable de 85,42

Le classifieur KNN couplé à la sélection PSO (basée sur nu-SVM) : cette configuration a permis d'obtenir des scores équilibrés en termes de précision, de rappel et de F1-score, garantissant une fiabilité prédictive optimale.

Le classifieur nu-SVM associé à la sélection PSO : cette combinaison a confirmé la robustesse de l'approche PSO, offrant des performances comparables et soulignant sa capacité à optimiser directement l'efficacité des classifieurs.

Parallèlement, les méthodes filter-based ont montré leur utilité, notamment l'Analyse en Composantes Principales (PCA) associée au modèle nu-SVM, qui a généré une précision de 84,17

Ce travail réaffirme le potentiel majeur des caractéristiques acoustiques en tant que biomarqueurs précoces et non invasifs de la maladie de Parkinson. Il souligne toutefois que la précision des modèles repose sur une sélection rigoureuse des attributs pour prévenir les phénomènes de surapprentissage et réduire la complexité inutile. Néanmoins, certaines limites subsistent : la taille restreinte du jeu de données actuel constitue un facteur limitant qui pourrait accentuer le risque de surapprentissage. Par conséquent, une validation sur des cohortes cliniques plus vastes et diversifiées demeure une étape indispensable pour la généralisation des résultats.

En perspective, plusieurs pistes de recherche pourraient enrichir cette étude. L'exploration des réseaux de neurones profonds (Deep Learning), notamment les réseaux de neurones convolutifs appliqués aux signaux vocaux bruts, ainsi que l'intégration de données multimodales — croisant indices acoustiques, données cliniques et imagerie médicale — ouvrirait de nouvelles voies pour une prédiction encore plus robuste. De plus, l'optimisation avancée des hyperparamètres, via des techniques de recherche bayésienne, permettrait d'affiner encore davantage la précision des modèles. Enfin, le passage du stade expérimental au déploiement en système d'aide à la décision médicale (MDSS) nécessitera une attention accrue portée à l'interprétabilité des modèles, afin de garantir leur acceptabilité et leur intégration fluide au sein des protocoles de soin clinique.

En conclusion, cette étude démontre que l'association de l'optimisation par essaim particulière (PSO) avec les classifieurs KNN ou nu-SVM constitue l'approche la plus performante pour la prédiction de la maladie de Parkinson, atteignant une précision maximale de 85,42

Annexe : Code source

L'ensemble du code Python utilisé pour ce projet est regroupé dans l'archive

`Parkinson_ML_Project.zip` fournie avec ce rapport. Cette archive contient les fichiers suivants :

- **parkinson.csv** : jeu de données utilisé (issu de UCI Repository).
- **output.png** : matrice de corrélation générée.
- **CfsSubsetEval.ipynb** : sélection de caractéristiques avec `CfsSubsetEval`.
- **pca.ipynb** : analyse en composantes principales (PCA).
- **sans_selection.ipynb** : classification sans sélection de variables.
- **wrapped_based_knn.ipynb** : wrapper-based feature selection avec KNN.
- **wrapped_based_nusvm.ipynb** : wrapper-based feature selection avec nu-SVM.
- **wrapped_based_rn.ipynb** : wrapper-based feature selection avec Random Forest.
- **wrapper_based_csvm.ipynb** : wrapper avec c-SVM comme base classifieur.
- **wrapper_based_mlp.ipynb** : wrapper avec MLP.
- **wrapper_based_NV.ipynb** : wrapper avec Naïve Bayes.
- **iG.ipynb** : Info Gain .
- **report.log** : fichier de log de génération des résultats.

Chaque notebook est autonome et documenté, permettant la reproduction complète des expériences décrites dans ce rapport. Pour exécuter ces fichiers, il est recommandé d'utiliser Jupyter Notebook avec un environnement Python 3.12 et les dépendances listées dans `requirements.txt`.